

Trabajo Final: Proyectos de Arquitectura de Datos en la Nube.

Objetivo: Diseñar, implementar y desplegar una arquitectura de datos end-to-end en Google Cloud Platform (GCP) que resuelva un problema de negocio. El proyecto gestionará tanto datos históricos (Procesamiento Batch) como flujos de eventos en tiempo real (Procesamiento Streaming), integrando modelos de Machine Learning y visualización.

Datos: Durante la Sesión 1 se presentará un catálogo con datos diferentes (Logística, E-commerce, IoT Agrícola, Minería de Procesos y Telemetría Web). Usted deberá seleccionar un único dataset que servirá como base para todo su proyecto.

Entregables: El proyecto se divide en dos grandes tuberías (pipelines) que deben operar de manera conjunta sobre su entorno de GCP:

Parte A: Arquitectura Batch (Análisis Histórico y Entrenamiento)

Ingesta: Un script en Python que simule la carga inicial de los datos históricos en crudo hacia Google Cloud Storage (Data Lake).

Procesamiento: Transformación y carga estructurada de los datos desde Storage hacia BigQuery (Data Warehouse).

Inteligencia Artificial: Entrenamiento de un modelo predictivo utilizando BigQuery ML directamente sobre los datos almacenados (ej. regresión logística, clasificación, etc.).

Visualización: Un panel en Looker Studio conectado a BigQuery que muestre métricas históricas de su negocio y los resultados de evaluación del modelo.

Parte B: Arquitectura Streaming (Flujo en Tiempo Real e Inferencia)

Ingesta: Un script en Python que lea su dataset y publique eventos uno a uno hacia un tópico de Pub/Sub, inyectando un timestamp actual para simular telemetría en vivo.

Procesamiento: Un pipeline en Dataflow (Apache Beam) que escuche el tópico de Pub/Sub, realice una transformación al vuelo (ej. calcular diferencias de valores o promedios en ventanas de tiempo) y escriba el resultado.

Inteligencia Artificial: Despliegue de un modelo como endpoint en Vertex AI, conectado al pipeline para realizar inferencias sobre los datos que van llegando.

Visualización: Un componente en Looker Studio que se actualice en tiempo real reflejando el pulso de los datos en vivo.

Gobernanza y FinOps: Al finalizar su trabajo y demostración, ningún recurso de cómputo debe quedar encendido. Ejecutar su script de limpieza (teardown) para apagar Jobs de Dataflow y Endpoints de Vertex AI.

Formato de Entrega:

Repositorio de Código: Un enlace a GitHub (o archivo .zip) con sus scripts de Python (Productor Pub/Sub, Ingesta Batch, script de limpieza) y consultas SQL importantes.

Capturas de pantalla de demostración:

Mostrar la arquitectura, la ejecución de los scripts en su terminal local, los mensajes llegando a Pub/Sub y siendo procesados por Dataflow en la consola de GCP, el dashboard de Looker Studio reaccionando a los datos (Batch y Streaming), ejecución del script de apagado y la confirmación en la consola de que Dataflow y Vertex AI fueron detenidos.

Rúbrica.

Categoría	Criterios de Evaluación	Puntaje Máximo
1. Ingesta de Datos (Batch y Streaming)	Batch (10 pts): El script de Python carga correctamente los datos históricos crudos hacia Google Cloud Storage.Streaming (10 pts): El script productor inyecta un timestamp válido y publica los eventos de forma secuencial en un tópico de Pub/Sub.	20
2. Procesamiento (Dataflow y BigQuery)	Batch (10 pts): Los datos se transforman y estructuran adecuadamente en BigQuery listos para análisis. Streaming (15 pts): El Job de Dataflow captura los mensajes de Pub/Sub, realiza al menos una transformación al vuelo y los escribe exitosamente en el destino (BigQuery/Firestore).	25
3. Machine Learning (Vertex AI y BQML)	Batch (10 pts): Se evidencia la creación y entrenamiento de un modelo utilizando BigQuery ML con resultados interpretables. Streaming (10 pts): El modelo está desplegado como un Endpoint en Vertex AI y el pipeline puede realizar inferencias sobre los nuevos datos.	20
4. Visualización (Looker Studio)	El dashboard integra ambas fuentes. Muestra métricas históricas de forma clara (Batch) e incluye componentes visuales que reaccionan a los datos en tiempo real (Streaming).	15
5. FinOps, Demostración y Limpieza	Demostración (10 pts): Documento con capturas de pantalla y breve explicación del flujo end-to-end resolviendo el caso de negocio. FinOps (10 pts): Capturas explícitas de la ejecución del script de limpieza (teardown) y la cancelación exitosa de recursos en consola (Dataflow, Vertex AI).	20
	PUNTAJE TOTAL	100