

Proyecto Final

Arquitectura de Datos E-commerce en Google Cloud

Erick Adrián Orozpe Frias

17 de mayo de 2026

Índice

Resumen ejecutivo	2
1. Flujo general de arquitectura	2
2. Pipeline de configuración	3
2.1. Cloud Storage como zona batch y artefactos	3
2.2. Dataflow streaming con UDF	3
2.3. Modelo BigQuery ML	4
3. Pipeline de ingesta y transformación	4
3.1. Publicación de eventos streaming	4
3.2. Función JavaScript de transformación	5
3.3. BigQuery transformado	5
4. Visualización en Looker Studio	6
5. BigQuery ML y Vertex AI	6
5.1. Inferencia batch con BigQuery ML	6
5.2. Registro y endpoint en Vertex AI	7
5.3. Prueba de inferencia online	7
6. FinOps y limpieza	8
7. Conclusiones	10

Resumen ejecutivo

Este proyecto implementa una arquitectura de datos end-to-end para e-commerce en Google Cloud Platform. La solución combina ingesta batch hacia Cloud Storage, publicación de eventos streaming con Python y Pub/Sub, procesamiento con Dataflow, almacenamiento analítico en BigQuery, visualización en Looker Studio, entrenamiento con BigQuery ML y despliegue de inferencia online con Vertex AI.

Los recursos principales del proyecto están disponibles en [Repositorio GitHub del proyecto](#) y en el [Dashboard de Looker Studio](#).

La estructura del repositorio separa datos, notebooks, consultas SQL, evidencias y recursos del dashboard:

Ruta	Contenido principal
Final/data/	Dataset CSV usado para la carga batch y la simulación streaming.
Final/notebook/	Notebooks de publicación a Pub/Sub y prueba del endpoint de Vertex AI.
Final/sql/	Consultas de creación de tablas, vistas, validaciones y ML.PREDICT.
Final/img/	Capturas de evidencia usadas en el reporte.
Final/dashboard/	Recursos o notas asociados al tablero.
Final/.gitignore	Reglas para excluir credenciales y archivos sensibles.
Final/README.md	Guía de navegación y reproducción del proyecto.

1. Flujo general de arquitectura

La arquitectura separa el flujo batch del flujo streaming. El batch conserva el archivo histórico en Cloud Storage y lo estructura en BigQuery. El streaming publica eventos JSON en Pub/Sub; Dataflow consume la suscripción, ejecuta una transformación con UDF JavaScript y escribe una tabla transformada en BigQuery. Desde ahí se alimenta Looker Studio y se ejecutan consultas de validación. Para la parte de ML, BigQuery ML entrena el modelo y Vertex AI lo expone como endpoint online.




Figura 1: Flujo general del proyecto: ingesta batch, streaming, transformación, analítica, visualización e inferencia online.

2. Pipeline de configuración

Esta sección documenta los recursos base que habilitan el pipeline: bucket de Cloud Storage, job de Dataflow y modelo de ML.

2.1. Cloud Storage como zona batch y artefactos

Se creó el bucket `ecommerce-data-lake-erick` en `us-central1`. Este bucket sirve para conservar el dataset histórico y almacenar artefactos auxiliares, como la UDF JavaScript usada por Dataflow.




Figura 2: Bucket de Cloud Storage usado como data lake y zona de artefactos del proyecto.

2.2. Dataflow streaming con UDF

La configuración de Dataflow usa la plantilla Pub/Sub to BigQuery. La parte no obvia es que Dataflow no genera datos: consume mensajes de una suscripción de Pub/Sub. Para demostrar transformación real, se agregó una UDF JavaScript en Cloud Storage que calcula campos derivados antes de escribir en BigQuery.




Figura 3: Job de Dataflow en ejecución con UDF JavaScript, procesando mensajes desde Pub/Sub hacia BigQuery.

2.3. Modelo BigQuery ML

El modelo `return_prediction_model` se entrenó con BigQuery ML para predecir devoluciones. Las columnas de entrada validadas en el modelo fueron `Quantity`, `UnitPrice` y `Country`. Esta restricción fue importante al invocar el endpoint de Vertex AI: cualquier campo adicional no esperado, como `CustomerID`, provoca error de esquema.




Figura 4: Evaluación del modelo BigQuery ML con métricas interpretables para validar el entrenamiento.

3. Pipeline de ingesta y transformación

3.1. Publicación de eventos streaming

El productor en Python lee el CSV local y publica eventos JSON hacia el tópico `ecommerce-topic`. Para la simulación se publicaron lotes pequeños y una muestra mayor de 10,000 eventos. El script inyecta fechas de evento para que la serie temporal en Looker Studio pueda mostrar variación por hora.

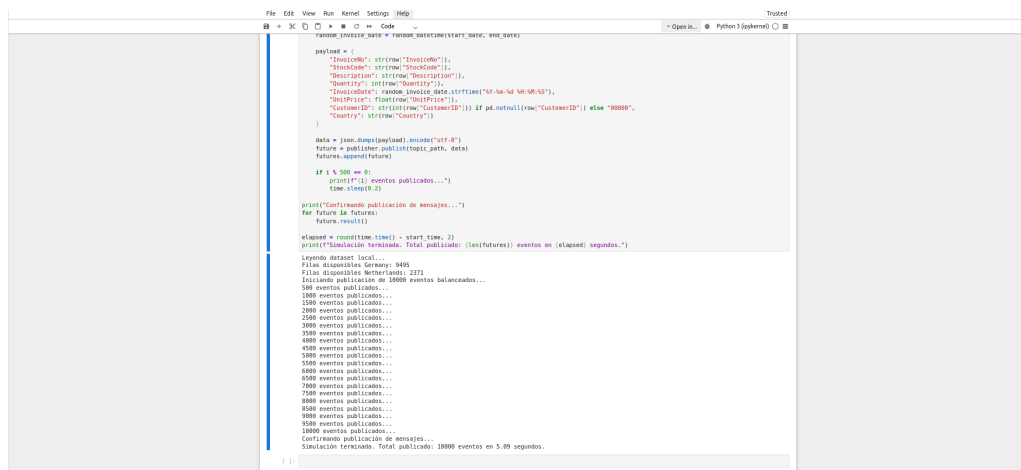


Figura 5: Publicación de 10,000 eventos desde Python hacia Pub/Sub para alimentar el pipeline streaming.

3.2. Función JavaScript de transformación

La UDF se guardó en Cloud Storage y se conectó al job de Dataflow usando la ruta del archivo JavaScript almacenado en el bucket del proyecto:

```
gs://ecommerce-data-lake-erick/udf/transform_ecommerce.js
```

Esta función agrega campos calculados que no venían en el JSON original.

Listing 1: Transformacion principal aplicada por la UDF.

```
function transform(inJson) {
  var obj = JSON.parse(inJson);
  var quantity = Number(obj.Quantity || 0);
  var unitPrice = Number(obj.UnitPrice || 0);
  var totalAmount = quantity * unitPrice;

  obj.Quantity = quantity;
  obj.UnitPrice = unitPrice;
  obj.TotalAmount = totalAmount;
  obj.Source = "pubsub_dataflow_udf";
  obj.IsHighValue = totalAmount >= 100;
  obj.InvoiceTimestamp = obj.InvoiceDate;
  obj.InvoiceHour = obj.InvoiceDate.substring(0, 13) + ":00:00";

  return JSON.stringify(obj);
}
```




Figura 6: Archivo JavaScript de transformación cargado en Cloud Storage para ser consumido por Dataflow.

3.3. BigQuery transformado

La tabla `streaming_sales_transformed` confirma la transformación al vuelo. Los campos agregados por la UDF son `InvoiceTimestamp`, `InvoiceHour`, `TotalAmount`, `Source` e `IsHighValue`.

Se está actualizando el cronograma de big de las consultas guardadas clásicas. Se proporcionará más información a fines de abril de 2025. Puedes seguir migrando tus consultas a las consultas guardadas de BigQuery Studio con la herramienta de migración.

Herramienta de migración Descartar

```

SELECT COUNT(*)
FROM `bueno-398482-ecommerce-data-streaming-sales-transformed`

```

Esta secuencia de comandos procesará 3.47 MB cuando se ejecute.

Resultados de la consulta

InvoiceDate	InvoiceHour	InvoiceTotal	UnitPrice	CustomerID	Country	TotalAmount	Source	IsHighValue
2028-05-17 12:20:57	2028-05-17 12:20:57 UTC	2028-05-17 12:20:00 UTC	7.08	13113	United Kingdom	70.8	pubsub_dataflow_usf	false
2028-05-17 12:21:30	2028-05-17 12:21:30 UTC	2028-05-17 12:20:00 UTC	0.85	12680	France	10.2	pubsub_dataflow_usf	false
2028-05-17 12:21:37	2028-05-17 12:21:37 UTC	2028-05-17 12:20:00 UTC	4.15	12680	France	16.6	pubsub_dataflow_usf	false
2028-05-17 12:20:54	2028-05-17 12:20:54 UTC	2028-05-17 12:20:00 UTC	8.95	13113	United Kingdom	214.7999999999	pubsub_dataflow_usf	true
2028-05-17 12:21:27	2028-05-17 12:21:27 UTC	2028-05-17 12:20:00 UTC	4.15	12680	France	16.6	pubsub_dataflow_usf	false
2028-05-17 12:21:34	2028-05-17 12:21:34 UTC	2028-05-17 12:20:00 UTC	2.1	12680	France	12.6000000000	pubsub_dataflow_usf	false
2028-05-17 12:20:44	2028-05-17 12:20:44 UTC	2028-05-17 12:20:00 UTC	1.95	13004	United Kingdom	23.4	pubsub_dataflow_usf	false
2028-05-17 12:21:21	2028-05-17 12:21:21 UTC	2028-05-17 12:20:00 UTC	1.95	12680	France	15.6	pubsub_dataflow_usf	false
2028-05-17 12:21:43	2028-05-17 12:21:43 UTC	2028-05-17 12:20:00 UTC	4.95	12680	France	14.8500000000	pubsub_dataflow_usf	false
2028-05-17 12:20:41	2028-05-17 12:20:41 UTC	2028-05-17 12:20:00 UTC	1.95	13113	United Kingdom	19.5	pubsub_dataflow_usf	false

Figura 7: Tabla transformada en BigQuery con columnas derivadas creadas por la UDF de Dataflow.

4. Visualización en Looker Studio

El dashboard se conectó a BigQuery para mostrar KPIs, tabla de eventos recientes, ventas por país y serie temporal. Un ajuste relevante fue crear o exponer InvoiceHour; sin ese campo, Looker agrupaba los eventos como un solo día y la serie temporal no era representativa.




Figura 8: Dashboard de Looker Studio conectado a BigQuery, con KPIs, tabla de eventos y visualizaciones por país y hora.

5. BigQuery ML y Vertex AI

5.1. Inferencia batch con BigQuery ML

ML.PREDICT se usó para validar inferencia dentro de BigQuery. Esta operación no modifica ni sobrescribe el modelo: únicamente aplica el modelo entrenado sobre un conjunto de entrada.

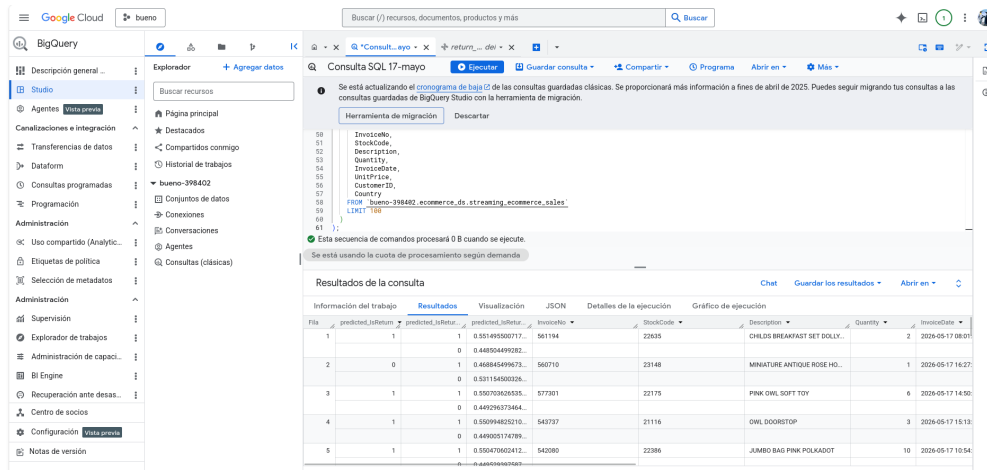


Figura 9: Resultado de ML.PREDICT sobre registros recientes de la tabla streaming.

5.2. Registro y endpoint en Vertex AI

El modelo entrenado en BigQuery ML se registró en Vertex AI Model Registry como **return-prediction-bqml**. Después se implementó en el endpoint **return-prediction-endpoint-v2**, habilitando inferencia online por API.

return-prediction-bqml

Editar detalles

Descripción del modelo

—

Región

us-central1 (Iowa)

Etiquetas de modelos

—

Versiones

Filtro

Ingresar un nombre de propiedad

ID de versión

Alias

Estado

Descripción

Extremos

Fecha de creación

Etiquetas

1

default

Implementado

—

return-prediction-endpoint-v2

17 may 2026, 12:31:18 p.m.

Figura 10: Endpoint de Vertex AI activo con un modelo implementado.

5.3. Prueba de inferencia online

La prueba se hizo desde Python usando el SDK de Vertex AI. La solicitud incluyó únicamente las columnas esperadas por el modelo: **Quantity**, **UnitPrice** y **Country**.

Listing 2: Solicitud mínima al endpoint de Vertex AI.

```

instances = [
    {
        "Quantity": 1,
        "UnitPrice": 9.99,
        "Country": "Germany"
    }
]

```

```
prediction = endpoint.predict(instances=instances)
print(prediction)
```

```
[12]: pred = prediction.predictions[0]

print("Resultado de inferencia en Vertex AI")
print("-----")
print(f"Entrada: {instances[0]}")
print(f"Predicción IsReturn: {pred['predicted_IsReturn'][0]}")
print(f"Probabilidades: {pred['IsReturn_probs']}")
print(f"Clases: {pred['IsReturn_values']}")

Resultado de inferencia en Vertex AI
-----
Entrada: {'Quantity': 1, 'UnitPrice': 9.99, 'Country': 'Germany'}
Predicción IsReturn: 1
Probabilidades: [0.5515341763211642, 0.4484658236788358]
Clases: ['1', '0']

Se probó el endpoint de Vertex AI usando una instancia con las variables Quantity, UnitPrice y Country, que son las columnas de entrada del modelo. El endpoint respondió correctamente con la predicción predicted_IsReturn = 1 y las probabilidades asociadas, validando la inferencia online del modelo desplegado.
```

Figura 11: Salida de inferencia online desde Python contra el endpoint de Vertex AI.

6. FinOps y limpieza

Al finalizar las pruebas, se apagaron recursos para evitar costos. En Dataflow se cancelaron los jobs de streaming. En Vertex AI se anuló la implementación del modelo: la evidencia clave es que el endpoint quedó con Modelos = 0.

Trabajos Crear trabajo a partir de una plantilla Crear trabajo a partir de un compilador Habilitar el ordenamiento Actualizar Administrar																																												
Los trabajos de Dataflow usan Cloud Storage para almacenar archivos temporales durante la ejecución de la canalización. Estos archivos tienen habilitada una política de eliminación no definitiva de forma predeterminada. Para evitar cobros por costos de almacenamiento innecesarios, desactiva la función de eliminación no definitiva en los buckets que usan tus trabajos de Dataflow para almacenamiento temporal. Más información																																												
En curso Archivado Filtro Filtrar trabajos <table> <thead> <tr> <th>Nombre</th><th>Tipo</th><th>Hora de finalización</th><th>Tiempo transcurrido</th><th>Hora de inicio</th><th>Estado</th><th>Versión del SDK</th><th>ID</th><th>Región</th></tr> </thead> <tbody> <tr> <td>streaming-ecommerce-transform-job</td><td>Transmisión</td><td>17 may 2026, 1:54:19 p.m.</td><td>1 h 36 min</td><td>17 may 2026, 12:17:20 p.m.</td><td>Cancelado</td><td>2.72.0</td><td>2026-05-17_11_17_19-16067818908665719663</td><td>us-central1</td></tr> <tr> <td>streaming-ecommerce-job</td><td>Transmisión</td><td>17 may 2026, 11:46:58 a.m.</td><td>1 h 2 min</td><td>17 may 2026, 10:44:14 a.m.</td><td>Cancelado</td><td>2.72.0</td><td>2026-05-17_09_44_13-16193215986665559856</td><td>us-central1</td></tr> <tr> <td>streaming-ecommerce-job</td><td>Transmisión</td><td>17 may 2026, 10:35:41 a.m.</td><td>12 min 38 s</td><td>17 may 2026, 10:23:03 a.m.</td><td>Cancelado</td><td>2.72.0</td><td>2026-05-17_09_23_02-2520090068749479446</td><td>us-central1</td></tr> </tbody> </table>									Nombre	Tipo	Hora de finalización	Tiempo transcurrido	Hora de inicio	Estado	Versión del SDK	ID	Región	streaming-ecommerce-transform-job	Transmisión	17 may 2026, 1:54:19 p.m.	1 h 36 min	17 may 2026, 12:17:20 p.m.	Cancelado	2.72.0	2026-05-17_11_17_19-16067818908665719663	us-central1	streaming-ecommerce-job	Transmisión	17 may 2026, 11:46:58 a.m.	1 h 2 min	17 may 2026, 10:44:14 a.m.	Cancelado	2.72.0	2026-05-17_09_44_13-16193215986665559856	us-central1	streaming-ecommerce-job	Transmisión	17 may 2026, 10:35:41 a.m.	12 min 38 s	17 may 2026, 10:23:03 a.m.	Cancelado	2.72.0	2026-05-17_09_23_02-2520090068749479446	us-central1
Nombre	Tipo	Hora de finalización	Tiempo transcurrido	Hora de inicio	Estado	Versión del SDK	ID	Región																																				
streaming-ecommerce-transform-job	Transmisión	17 may 2026, 1:54:19 p.m.	1 h 36 min	17 may 2026, 12:17:20 p.m.	Cancelado	2.72.0	2026-05-17_11_17_19-16067818908665719663	us-central1																																				
streaming-ecommerce-job	Transmisión	17 may 2026, 11:46:58 a.m.	1 h 2 min	17 may 2026, 10:44:14 a.m.	Cancelado	2.72.0	2026-05-17_09_44_13-16193215986665559856	us-central1																																				
streaming-ecommerce-job	Transmisión	17 may 2026, 10:35:41 a.m.	12 min 38 s	17 may 2026, 10:23:03 a.m.	Cancelado	2.72.0	2026-05-17_09_23_02-2520090068749479446	us-central1																																				
Prueba plantillas Instructivo 15 min Usa la plantilla de WordCount proporcionada por Google para realizar un recuento de la frecuencia de palabras en obras de Shakespeare. Prueba Java Instructivo Usa el SDK de Java para configurar una canalización que realice un recuento de frecuencia de palabras en obras de Shakespeare. Prueba Python Instructivo Usa el SDK de Python para configurar una canalización que realice un recuento de frecuencia de palabras en obras de Shakespeare. Prueba notebooks Documento de ayuda Aprende a ejecutar canalizaciones de Beam de forma interactiva y trabajos de Dataflow con notebooks de JupyterLab. Toda la documentación de Dataflow																																												

Figura 12: Secuencia FinOps 1: modelo implementado en Vertex AI durante la prueba de inferencia.

return-prediction-bqml		Editar detalles	
Descripción del modelo		Región	Etiquetas de modelos
—		us-central1 (Iowa)	—
Versiones			
Filtro Ingresar un nombre de propiedad			
☐	ID de versión ↓	Alias	Estado
☐	1	default	Implementado
		Descripción	Extremos
		—	return-prediction-endpoint-v2
		Fecha de creación	Etiquetas
		17 may 2026, 12:31:18 p.m.	

Figura 13: Secuencia FinOps 2: endpoint activo con un modelo desplegado antes de la limpieza.

Extremos

Extremos

Grupos de recursos de implementación

Los extremos son modelos de aprendizaje automático disponibles para las solicitudes de inferencia en línea. Además, son útiles para las inferencias oportunas de muchos usuarios (por ejemplo, en respuesta a una solicitud de aplicación). También puedes solicitar inferencias por lotes si no necesitas resultados inmediatos.

Para crear un extremo, necesitas al menos un modelo de aprendizaje automático. [Más información](#)

Región

us-central1 (Iowa)

Extremos

Crear

Actualizar

Filtro

Ingresar un nombre de propiedad

☐	Nombre	ID	Estado	Modelos	Grupo de recursos de implementación	Región	Supervisión	Alertas más recientes	Última actualización ↓	API
☐	return-prediction-endpoint-v2	5252543517502210048	Listo	0	—	us-central1	Inhabilitada	—	17 may 2026, 1:58:07 p.m.	Solicitud de mu
☐	return-prediction-endpoint	4140154409541697536	No se pudo crear	0	—	us-central1	Inhabilitada	—	17 may 2026, 12:52:33 p.m.	—

Figura 14: Secuencia FinOps 3: endpoint sin modelos implementados, evidenciando la limpieza del recurso de inferencia.

streaming-ec...		Clonar	Detener	Crear instantánea	Archivar	Compartir	Enviar comentarios	Información del trabajo	
Gráfico del trabajo		Detalles de la ejecución						Vista de los pasos del trabajo	
Vista de gráfico		ReadPutScrip... Detenido Retraso de los datos: 1 min 35.86 s < 1% tiempo total Latencia máxima de la operación: < 1 etapa ConvertMe... Detenido						Nombre del trabajo streaming-commerce-transform-job ID de trabajo 2026-05-17_11_17_19-16067818908665719663 Tipo de trabajo Transmisión Estado del trabajo Cancelado Versión del SDK Apache Beam SDK for Java 2.72.0 Región del trabajo us-central1 Zonas de servicio us-central1-c Ubicación del trabajador us-central1 Trabajadores actuales 0 Estado más reciente del trabajador Se detuvo el grupo de trabajadores. Estado del rezagado No hay rezagados activos Hora de inicio 17 de mayo de 2026, 12:17:20 p.m. GMT-6 Tiempo transcurrido 1 h 36 min Tipo de encriptación Administrada por Google Dataflow Prime Inhabilitada Línea de Knowledge Catalog Inhabilitada Runner v2 Inhabilitada Streaming Engine Habilitada Ajuste de escala automático vertical Inhabilitada Modo de transmisión Al menos una vez	
Registros		Registros de trabajos						Registros de trabajador	
Gravedad		Filtro Buscar en todos los campos y valores						Muestreo de datos	
Gravedad		Resumen						2026-05-17 12:19:11.122 CST Worker configuration: n1-standard-2 in us-central1-c. 2026-05-17 12:19:12.812 CST Streaming job has set up its own fixed sharding configuration. Liquid sharding will be disabled. Parallelism will be... 2026-05-17 12:19:13.288 CST Running job using Streaming Engine 2026-05-17 12:19:13.222 CST Using correctness mode 'at-least-once'. Duplicate data may be present in output. 2026-05-17 12:19:13.512 CST Starting 1 workers in us-central1... 2026-05-17 12:20:49.921 CST All workers have finished the startup processes and began to receive work requests. 2026-05-17 13:53:07.185 CST Cancel request is committed for workflow job: 2026-05-17_11_17_19-16067818908665719663. 2026-05-17 13:53:07.228 CST Stopping worker pool...	

Figura 15: Jobs de Dataflow cancelados como parte de la limpieza del ambiente.

7. Conclusiones

La implementación cubre el flujo completo solicitado: ingesta batch, ingesta streaming, transformación con Dataflow, almacenamiento en BigQuery, visualización en Looker Studio, entrenamiento con BigQuery ML e inferencia online con Vertex AI. Los pasos no obvios más importantes fueron: usar una UDF para que Dataflow transformara realmente los eventos, crear campos temporales para que el dashboard mostrara una serie por hora, enviar al endpoint solo las columnas esperadas por el modelo y limpiar recursos activos para FinOps.